

15.4. Eiropas ilgtspējīga attīstība

Jekaterīna Butkeviča

2026. gads 22. janvāris

Vispārējie R koda bloku iestatījumi:

```
knitr::opts_chunk$set(echo = TRUE, warning = FALSE, message = FALSE)
library(tidyverse)
library(readxl)
library(Rtsne)
library(janitor)
library(dplyr)
library(umap)
library(foreign)
library(kernlab) # KPCA
library(reticulate) # TriMap, PaCMAP
```

Uzdevums

1. Izpētiet piedāvātos datus, izmantojot pēc iespējas vairāk no datizraces kursā apgūtajām metodēm.
2. Kolonnā BA ir dots t.s. Advanced Human Development Index (AHDH, detaļas - publikācijā). Viens no Jūsu pētījuma mērķiem varētu būtu pēc iespējas mazākas raksturlielumu apakškopas atrašana, no kuras katrai valstij AHDH varētu pietiekami precīzi aprēķināt.

Dati

Cik es sapratu, pēc pirmā acu uzmetiena – datu kopa ir izveidota, lai atbalstītu matemātiskā modeļa izstrādi pilsētu ilgtspējīgas attīstības mērīšanai, kas atbilst ANO noteiktajiem standartiem. Dati ir sadalīti divās galvenajās lapās:

1. Pirmā lapa satur specifiskus ilgtspējīgas attīstības mērķu (Sustainable Development Goals – SDG) indikatorus. Šajā lapā dati ir apkopoti par 27 ES valstīm.
2. Otrā lapa satur aprēķinātos globālos indeksus. Tā sastāv no piecām kolonnām (Valsts, HDI 2020, EPI 2020 un aprēķinātais AHDH). Šajā sarakstā ir iekļautas arī valstis ārpus ES.

Es nolasīju un attīrīju datus. Pirmajā tabulā izdzēsu liekās rindas (“gads” un “avots”), pārsaucu pirmo kolonnu un izņēmu AHDH indeksu, jo tas bija neērti izvietots. Tabulas apvienoju pēc valsts nosaukuma, tādējādi atgriežot AHDH indeksu. Pa ceļam saglabāju datu tabulu WEKA formātā.

```
ind_data <- read_excel("Datizracei.xlsx", sheet = "Sheet1")
ind_clean <- ind_data %>%
```

```

filter(!Indikators %in% c("Gads", "Avots")) %>%
rename(Country = Indikators) %>%
select(1:50)

ahdi_data <- read_excel("Datizracei.xlsx", sheet = "Sheet2")

ahdi_clean <- ahdi_data %>%
  select(Country = 1, AHDI = 5) %>%
  filter(!is.na(AHDI))

full_df <- inner_join(ind_clean, ahdi_clean, by = "Country")
full_df$Country <- as.factor(full_df$Country)

write.arff(full_df, file = "full_df.arff")

```

Tālāk sagatavoju skaitlisko matricu analīzei: konvertēju to uz numeric formātu, valsts kolonnu pārvēršu par rindu nosaukumiem, standartaizēju matricu, bet mērķa mainīgo saglabāju atsevišķā vektorā.

```

row_names <- full_df$Country
analysis_df <- full_df %>%
  select(-Country) %>%
  mutate(across(everything(), as.numeric)) %>%
  as.data.frame()

rownames(analysis_df) <- row_names
analysis_df <- na.omit(analysis_df)

X <- as.matrix(analysis_df %>% select(-AHDI))
X_scaled <- scale(X)
ahdi_values <- analysis_df$AHDI

```

WEKA — indeksa prognozēšana

Ielasu iepriekš sagatavoto tabulu Wekā, taču noņēmu kolonnu ar valsti. Cilnē “Select attributes” izvēlējos Attribute Evaluator CfsSubsetEval ar noklusējuma iestatījumiem, bet kā Search Method izmantoju BestFirst. Kā mērķa mainīgo izvēlējos AHDI, un Attribute Selection Mode iestatīju uz krustenisko validāciju ar 10 foldiem (seed = 1).

Atribūtu selekcijas mērķis ir atrast tādu atribūtu kopu, kurā atribūti cieši korelē ar mērķa mainīgo, bet vāji korelē savā starpā. Tā kā izmantota krusteniskā validācija, rezultātā tiek parādīta nevis viena konkrēta atribūtu kopa, bet gan tas, cik bieži katrs atribūts tika izvēlēts 10 iterācijās.

```
=== Attribute selection 10 fold cross-validation seed: 1 ===
```

```

number of folds (%)  attribute
                3( 30 %)      1 G3.1

```

0(0 %)	2 G3.2
1(10 %)	3 G3.3
0(0 %)	4 G3.4
2(20 %)	5 G3.5
8(80 %)	6 G3.6
10(100 %)	7 G3.7
1(10 %)	8 G4.1
2(20 %)	9 G4.2
0(0 %)	10 G4.3
0(0 %)	11 G4.4
1(10 %)	12 G4.5
0(0 %)	13 G5.1
1(10 %)	14 G5.2
0(0 %)	15 G5.3
10(100 %)	16 G5.4
0(0 %)	17 G5.5
0(0 %)	18 G5.6
0(0 %)	19 G5.7
1(10 %)	20 G6.1
1(10 %)	21 G6.2
0(0 %)	22 G6.3
0(0 %)	23 G7.1
9(90 %)	24 G7.2
0(0 %)	25 G8.1
1(10 %)	26 G8.2
0(0 %)	27 G8.3
10(100 %)	28 G9.1
9(90 %)	29 G9.2
0(0 %)	30 G9.3
0(0 %)	31 G9.4
2(20 %)	32 G9.6
0(0 %)	33 G9.7
9(90 %)	34 G9.8
0(0 %)	35 G9.9
7(70 %)	36 G9.10
0(0 %)	37 G9.11
0(0 %)	38 G11.1
1(10 %)	39 G11.2
0(0 %)	40 G11.3
10(100 %)	41 G11.4
7(70 %)	42 G12.1
1(10 %)	43 G12.2
0(0 %)	44 G13.1
0(0 %)	45 G13.2
0(0 %)	46 G15.1
1(10 %)	47 G16.1
10(100 %)	48 G16.2
0(0 %)	49 G17.1

Rezultāts: Atribūti, kas atlasīti 90–100% gadījumu, ir visuzticamākie AHDI prognozēšanai. Man sanāca, ka tie ir:

- G3.7 (Novēršamā mirstība, uz 100 000 iedzīvotāju vecumā līdz 75 gadiem),
- G5.4 (Atšķirība labas vai ļoti labas pašvērtētās veselības īpatsvarā, vīrieši – sievietes, iedzīvotāji vecumā 16 gadi un vairāk, procentu punkti),
- G7.2 (Iedzīvotāju īpatsvars, kuri nevar pienācīgi apsildīt mājokli pēc nabadzības statusa, %),
- G9.1 (Nodarbinātība augsto un vidēji augsto tehnoloģiju ražošanā un zināšanu intensīvās pakalpojumu nozarēs; % no kopējās nodarbinātības),
- G9.2 (Uzņēmumu īpatsvars, kuriem ir ERP programmatūra informācijas apmaiņai starp dažādām funkcijām (10+ darbinieki),
- G9.8 (MVU īpatsvars ar iekšējām inovāciju aktivitātēm (EIS),
- G11.4 (raksta par šo informācijas nav) un G16.2 (Tiesu sistēmas uztvertā neatkarība, % iedzīvotāju, kas to vērtē kā ļoti vai diezgan labu).

Indikatoru aprakstus sagatavoja ChatGPT. Beigās pieliku arī pilno indikatoru sarakstu.

Tagad cilnē “Preprocess”, izmantojot filtru `unsupervised.attribute.Remove`, es izņēmu kolonnas, kas nebija minētas iepriekš, t.i. 1-6, 8-15, 17-23, 25-27, 30-33, 35-40, 42-47, 49 (kolonnu numuri). Atstāju arī AHDI kolonnu.

Cilnē “Classify” izvēlējos algoritmu `functions.LinearRegression` ar noklusējuma iestatījumiem.

```
Instances: 27
Attributes: 9
           G3.7
           G5.4
           G7.2
           G9.1
           G9.2
           G9.8
           G11.4
           G16.2
           AHDI
Test mode: 10-fold cross-validation

=== Classifier model (full training set) ===

Linear Regression Model

AHDI =
      -0.0001 * G3.7 +
      -0.0021 * G7.2 +
       0.0014 * G9.1 +
       0.0011 * G9.2 +
```

```
0.001 * G16.2 +  
0.7519
```

Time taken to build model: 0.04 seconds

=== Cross-validation ===

=== Summary ===

Correlation coefficient	0.9263
Mean absolute error	0.016
Root mean squared error	0.0204
Relative absolute error	33.0879 %
Root relative squared error	36.7286 %
Total Number of Instances	27

Rezultāts: Izmantojot lineāro regresiju, tika iegūts vienādojums no modelī iekļautajiem mainīgajiem. Vienādojumā netika iekļauti visi mainīgie – indikatori G5.4, G9.8 un G11.4 tika atstāti malā, jo WEKA algoritms LinearRegression automātiski veic papildu atribūtu atlasī, lai novērstu multikolinearitāti.

Iegūtais korelācijas koeficients ir ļoti augsts (~0,93), kas nozīmē, ka starp izvēlētajiem ilgtspējīgas attīstības indikatoriem un AHDl pastāv ļoti cieša lineāra saistība. Pacelot koeficientu kvadrātā, modelis spēj izskaidrot aptuveni 85,8% no AHDl indeksa vērtību variācijas starp ES valstīm. MAE ir maza – 0,016, un RRSE ir 36,7%, kas, ņemot vērā nelielo izlases apjomu, manuprāt, ir pieņemami.

Saskaņā ar vienādojuma koeficientiem indikatoriem G9.1 (Augstās tehnoloģijas), G9.2 (ERP programmatūra) un G16.2 (Tiesu sistēmas neatkarība) ir pozitīva ietekme uz AHDl indeksu – šie rādītāji veicina AHDl pieaugumu. Tas norāda, ka jo modernāka ir valsts rūpniecība un digitālā vide, jo augstāks ir cilvēka attīstības līmenis.

Savukārt indikatori G3.7 (Novēršamā mirstība) un G7.2 (Nespēja apsildīt mājokli) ietekmē AHDl negatīvi – pieaugot enerģētiskajai nabadzībai un novēršamai mirstībai (kas liecina par vāju veselības sistēmu), AHDl indekss samazinās.

Vienīgais, cik saprotu, WEKA automātiski nepārbauda lineārās regresijas priekšnosacījumus. Pakonsultējoties ar Gemini, viņa norādīja: “WEKA ir datizraces (data mining) rīks, un tās filozofija atšķiras no klasiskās statistikas programmatūras (piemēram, SPSS vai R lm funkcijas). Tā koncentrējas uz prognozēšanas precizitāti, nevis uz teorētisko modeļa”pareizību”. Nu labi, ar sievieti, kas tev palīdz, labāk nestrīdēties — lai ir, kā viņa saka.

Meta-algoritmi

Tagad vēlos salīdzināt rezultātus ar meta-algoritmiem. Cilnē “Classify” izvēlos meta-algoritmu Bagging, kā bāzes algoritmu izmantoju functions.LinearRegression, ar numIterations = 10. Pārbaudes režīms ir krusteniskā validācija.

```
=== Cross-validation ===  
=== Summary ===
```

Correlation coefficient	0.9364
Mean absolute error	0.0142
Root mean squared error	0.0188
Relative absolute error	29.2903 %
Root relative squared error	33.7816 %
Total Number of Instances	27


Izmantojot meta-algoritmu Bagging, korelācijas koeficients pieauga no 0.9263 līdz 0.9364, savukārt MAE samazinājās līdz 0.0142.

Manuprāt, iegūtie rezultāti atbilst mērķim – atrast pēc iespējas mazāku raksturlielumu apakškopu, no kuras katrai valstij AHDI varētu pietiekami precīzi aprēķināt. Kursā uzdevumā bija norādīts izmantot pēc iespējas vairāk kursā apskatīto algoritmu, taču es pielietāju tos, kas kursā tika konceptuāli pieminēti, bet nefigurēja mājasdarbos. Tāpēc es vēl pievienošu kādu papildus algoritmu, lai segtu šo prasību.

Galveno komponentu analīze (PCA)

Jau vairākas reizes esmu sniegusi PCA aprakstu, šoreiz to izlaižu. Aprēķinu visu nepieciešamo un pārbaudu galveno komponentu nozīmīgumu, izmantojot Kaisera–Guttmana kritēriju. Apskatu, kuriem indikatoriem pirmajās trīs komponentēs ir lielāki svāri.

```
pca_res <- prcomp(X_scaled)  
eigen_values <- pca_res$sdev^2  
plot(eigen_values, type = "b", main = "PCA Scree Plot",  
      xlab = "Komponente", ylab = "Īpašvērtība (Eigenvalue)")
```



```
eigen_values[eigen_values > mean(eigen_values)]

## [1] 14.056965  6.077252  4.351952  3.305424  2.813490  2.485730  2.200839
## [8]  2.026691  1.892838

#summary(pca_res) #daudz teksta
f <- pca_res$rotation
thr <- 0.15

pc123_strong <- lapply(1:3, function(i) {
  load <- f[, i]
  load[abs(load) > thr]
}))

names(pc123_strong) <- paste0("PC", 1:3)
pc123_strong

## $PC1
##      G3.6      G3.7      G4.2      G4.3      G4.4      G5.3
G5.4
## -0.1825849 -0.1693143  0.1997621  0.1874491  0.2148719 -0.1584769 -
0.1525677
##      G5.5      G5.6      G6.1      G6.2      G8.1      G8.2
G9.1
##  0.1733464  0.1514596 -0.1723107 -0.1846816  0.1578555  0.1994387
0.2127395
##      G9.2      G9.6      G9.7      G9.8      G9.9      G9.11
G11.3
##  0.1662586  0.2063300  0.2023417  0.1800016  0.1844773  0.1671924 -
0.1756163
##      G11.4      G12.1      G16.1      G16.2
##  0.1916673  0.1658787  0.2214789  0.2055827
##
## $PC2
##      G3.1      G3.7      G5.1      G5.2      G5.3      G5.4
G7.1
## -0.3088067  0.2464802  0.2008235  0.3236124 -0.2341884  0.1622340
0.2814575
##      G8.1      G9.10      G11.2      G11.4      G15.1
##  0.1518591  0.2482947 -0.2464092 -0.1541060  0.2540123
##
## $PC3
##      G3.3      G3.5      G3.6      G4.1      G8.1      G8.3
G9.4
##  0.2611927 -0.2129282 -0.1904663 -0.2141086 -0.2177982  0.3405876 -
0.2344526
##      G9.7      G9.8      G9.9      G9.11      G11.3      G15.1
G17.1
##  0.1920439  0.2015145  0.2276189  0.2146904  0.1941169  0.2231277 -
0.3432129
```

Rezultāts: Saskaņā ar Kaisera–Guttmana kritēriju nozīmīgas ir 9 asis.

Importance of components:						
	PC1	PC2	PC3	PC4	PC5	PC6
Standard deviation	3.7493	2.4652	2.08613	1.81808	1.67735	1.57662
Proportion of Variance	0.2869	0.1240	0.08882	0.06746	0.05742	0.05073
Cumulative Proportion	0.2869	0.4109	0.49972	0.56718	0.62459	0.67532
	PC7	PC8	PC9	PC10	PC11	PC12
Standard deviation	1.48352	1.42362	1.37580	1.21968	1.10721	1.05815
Proportion of Variance	0.04492	0.04136	0.03863	0.03036	0.02502	0.02285
Cumulative Proportion	0.72024	0.76160	0.80023	0.83059	0.85561	0.87846

Visas 9 nozīmīgās komponentes kopā izskaidro 80 % no kopējās datu variācijas (nevis AHDl variācijas, kā tas bija ar uzraudzīto mācīšanos WEKA, jo šeit AHDl esmu izslēgusi). Savukārt pirmās 3 komponentes kopā izskaidro 49,97 % no kopējās datu variācijas.

Faktoru ir daudz, tāpēc nav iespējams ievietot visu faktoru koeficientus katrai galvenajai komponentei. Tāpēc interpretēšu koeficientus tikai pirmajām trim komponentēm, ignorējot pārējos faktorus to lielā skaita dēļ.

Pirmajā komponentē daļai indikatoru, kuru koeficienti ir $\geq 0,15$, ietilpst: G4.4 (Pieaugušo izglītība) (0.21), G4.3 (Augstākā izglītība) (0.19), G9.1 (nodarbinātība augsto tehnoloģiju ražošanā) (0.21), G9.6–G9.9 (Inovācijas aktivitātes) (0.18 - 0.21), G8.2 (Jauniešiem paredzētie darbinieki) (0,20) un G5.5 / G5.6 (Sieviešu politiskā pārstāvniecība) (0.15-0.17). Indikatori ar koeficientiem $\leq 0,15$: G3.6 (Mirstība līdz 5 gadu vecumam) (-0.18), G3.7 (Novēršamā mirstība) (-0.17), G6.1 / G6.2 (Slikti mājokļa apstākļi) (-0.17 - -0,18) un G5.3 (Dzimumu nodarbinātības atšķirība) (-0.16). Šī komponente raksturo vispārējos sociāli ekonomiskos aspektus un cilvēku attīstības un labklājības līmeni. Lai gan aprakstā nav minēti visi indikatori, svarīgi atzīmēt, ka ar sliekšni 0,15 pirmā komponente iekļauj 7 no 8 ar WEKA atribūtu selekciju atlasītajiem mainīgajiem (tostarp 4 no 5, kas izvēlēti regresijas modelim).

Otru komponenti veido šādi indikatori: G5.2 (Dzimumu atšķirības izglītībā) (0.32), G7.1 (Atjaunojamā enerģija) (0.28), G3.7 (Novēršamā mirstība) (0.25), G5.3 (Dzimumu nodarbinātības atšķirība) (-0.23), G3.1 (Pašvērtētā veselība) (-0.31). Šī komponente atdala valstis pēc sociālās struktūras un atspoguļo sociālās nevienlīdzības, enerģētikas un veselības aspektus.

Trešo komponenti veido šādi indikatori: G8.3 (Ilgttermiņa bezdarbs) (0.34), G9.9 (Inovāciju izdevumi) (0.23), G3.3 (Neapmierinātas medicīniskās vajadzības) (0.26). Tā drīzāk raksturo nestabilitāti un pārejas procesus.

Vieglais gals – te ir interesanti.

27. komponentes īpašvērtība ir 2.772248e-30 jeb 0.000000000000000000000000002772248, kas, manuprāt, ir pietiekami tuvu nullei. To visvairāk veido mainīgie: G3.5 (Jaundzimušo mirstība) (-0.33), G4.1 (Priekšlaicīga izglītības

pamešana) (-0.28), G4.3 (Augstākā izglītība) (-0.22), G9.3 (Rūpniecības pievienotā vērtība) (-0.21), G12.1 (Pašvaldību atkritumu pārstrāde) (-0.20), G4.4 (Pieaugušo mūžizglītība) (0.29), G13.2 (Vides piesārņojuma problēmas) (0.28), G6.2 (Nav iekštelu tualetes) (0.23), G4.5 (STEM absolventi) (0.21), G11.4 (Smaga mājošanas deprivācija) (0.20), G3.6 (Bērnu mirstība līdz 5 gadiem) (0.20).

Saskaņā ar jūsu metodiku tas, ka 27. komponentes īpašvērtība ir tuvu nullei, liecina par stingru lineāru saistību starp indikatoriem, kuriem šajā komponentē ir piešķirts liels svars. Tas nozīmē, ka šie rādītāji dublē informāciju par valsts sociālekonomisko stāvokli, un dimensiju redukcijas procesā tie ir savstarpēji aizvietojami, ļaujot AHDl prognozēšanā izmantot tikai reprezentatīvākos no tiem.

No visiem šiem indikatoriem WEKA atribūtu selekcija atlasīja tikai vienu – G11.4 (smaga mājošanas deprivācija).

Faktoru analīze

Lai WEKAS atlasītajai (regresijā iekļauto faktoru) apakškopai piešķirtu nosaukumu :-).

```
weka_subset <- c("G3.7", "G7.2", "G9.1", "G9.2", "G16.2")
X_subset <- X_scaled[, weka_subset]

fa_res <- factanal(X_subset, factors = 2, rotation = "varimax")
print(fa_res$loadings, cutoff = 0.4)

##
## Loadings:
##      Factor1 Factor2
## G3.7  -0.637
## G7.2      -0.691
## G9.1   0.464   0.839
## G9.2   0.811
## G16.2  0.541   0.506
##
##      Factor1 Factor2
## SS loadings    1.575    1.560
## Proportion Var  0.315    0.312
## Cumulative Var  0.315    0.627
```

Iespējamā interpretācija:

1. faktors: Tehnoloģiskās attīstības un efektivitātes faktors, kas izskaidro aptuveni 31,5% no datu kopējās variācijas. Tajā dominē indikatoru: G9.2 (ERP programmatūra uzņēmumos) (0,811), kas norāda uz uzņēmējdarbības procesu digitalizāciju; G3.7 (Novēršamā mirstība) (-0,637), kur negatīvs svars liecina, ka pieaugot tehnoloģiskajam līmenim, mirstība samazinās; un G16.2 (Tiesu sistēmas neatkarība) (0,541), kas liecina, ka stabila tiesiskā vide ir saistīta ar tehnoloģisko attīstību.

2. faktors: Zināšanu ekonomikas un sociālās ilgtspējas faktors izskaidro aptuveni 31,2% no variācijas. Šajā faktorā dominē G9.1 (Nodarbinātība augsto tehnoloģiju nozarēs) (0,839) kā galvenais aspekts, G7.2 (Nespēja apsildīt mājokli) (-0,691), kas negatīvi korelē un, iespējams, liecina, ka valstīs ar augstu zināšanu ekonomikas īpatsvaru enerģētiskā nabadzība ir zemāka, kā arī G16.2 (Tiesu sistēmas neatkarība) (0,506), norādot uz tiesiskuma nozīmi.

Interesanti, ka G16.2 ir vienīgais indikators ar svaru virs 0,50 abos faktoros. To var interpretēt kā apliecinājumu, ka tiesu sistēmas neatkarība ir fundamentāls rādītājs, kas ietekmē gan tehnoloģisko uzņēmējdarbību, gan zināšanu ekonomiku, un kalpo par pamatu visai AHDl indeksa struktūrai. Savukārt G7.2 un G3.7 ar negatīvajiem svāriem rāda, ka AHDl pieaugums visstraujāk notiek, kad valsts pāriet no pamata vajadzību nodrošināšanas uz augsto tehnoloģiju ekonomiku.


t-SNE un UMAP

Lai apskatītu datus.

```
#t-SNE
set.seed(42)
tsne_out <- Rtsne(X_scaled, perplexity = 5)

plot(tsne_out$Y, col = "steelblue", pch = 16, main = "t-SNE (perplexity=10)",
      xlim = range(tsne_out$Y[,1]) + c(-5, 5),
      ylim = range(tsne_out$Y[,2]) + c(-5, 5))
text(tsne_out$Y, labels = rownames(analysis_df), cex = 0.5, pos = 4)
```

t-SNE (perplexity=10)




```
#UMAP
umap_out <- umap(X_scaled, n_neighbors = 5)
xrange <- range(umap_out$layout[,1])
yrange <- range(umap_out$layout[,2])
xpad <- 0.05 * diff(xrange)
ypad <- 0.05 * diff(yrange)

plot(umap_out$layout, col="firebrick", pch=16,
     main="UMAP (n_neighbors=5)",
     xlim=c(xrange[1]-xpad, xrange[2]+xpad),
     ylim=c(yrange[1]-ypad, yrange[2]+ypad))

text(umap_out$layout, labels=rownames(analysis_df), cex=0.6, pos=3)
```

UMAP (n_neighbors=5)



Abos grafikos izvietojums ir loģisks – Zviedrija, Dānija un Somija atrodas blakus viena otrai, Latvija un Lietuva arī (un vispār valstis, kuru AHD1 rādītāji ir līdzīgi). Tas norāda, ka dati ir strukturēti un līdz ar to reducējami.

P.S.

Tas gan nav „pēc iespējas vairāk kursā apskatīto metožu”, taču es arī neredzu jēgu pielietot daudz algoritmu, kas beigās dos vienu un to pašu rezultātu un vienkārši jāapkopo vispārīgā aprakstā. Tagad, manuprāt, sanāca labi — dažādas metodes ar dažādiem mērķiem, un, saliekot tās kopā, izveidojas diezgan sakarīgs rezultāts.

Pielikums – Indikātoru atšifrējums angļiski un latviski

G3 – Veselība

G3.1 Share of people with good or very good perceived health, % of population aged 16 or over – Labas vai ļoti labas pašvērtētās veselības īpatsvars, % iedzīvotāju vecumā 16 gadi un vairāk (Eurostat);

G3.2 Obesity rate by body mass index (BMI), % of population aged 18 or over – Aptaukošanās līmenis pēc ķermeņa masas indeksa (KMI), % iedzīvotāju vecumā 18 gadi un vairāk (Eurostat);

G3.3 Self-reported unmet needs for medical examination and care, % of population aged 16 or over – Pašnovērtētas neatbilstošas medicīniskās aprūpes vajadzības, % iedzīvotāju vecumā 16 gadi un vairāk (Eurostat);

G3.4 Number of generalist medical practitioners, per 100 000 population – Vispārējās prakses ārstniecības darbinieku skaits uz 100 000 iedzīvotāju (Eurostat);

G3.5 Neonatal mortality rate, per 1000 live births – Neonatālā mirstība, uz 1000 dzīvi dzimušiem (WB);

G3.6 Under-five mortality rate, per 1000 live births – Mirstība līdz 5 gadu vecumam, uz 1000 dzīvi dzimušiem (WB);

G3.7 Avoidable mortality, per 100 000 population below 75 years – Novēršamā mirstība, uz 100 000 iedzīvotāju vecumā līdz 75 gadiem (Eurostat).

G4 – Izglītība

G4.1 Early leavers from education and training, % of population aged 18 to 24 – Agrīnie izglītības un apmācības pārtrauktāji, % iedzīvotāju vecumā 18–24 gadi (Eurostat);

G4.2 Share of top performers in at least one subject (level 5 or 6) – Labākie sasniegumi vismaz vienā mācību priekšmetā (līmenis 5 vai 6) (OECD);

G4.3 Share of population with tertiary education (levels 5-8 ISCED 2011) from 15 to 64 years – Augstākās izglītības ieguvēju īpatsvars (līmeņi 5–8, ISCED 2011), vecumā 15–64 gadi (Eurostat);

G4.4 Adult participation rate in education and training (last 12 months), from 25 to 64 years – Pieaugušo piedalīšanās izglītībā un apmācībā (pēdējo 12 mēnešu laikā), vecumā 25–64 gadi (Eurostat);

G4.5 Graduates in tertiary education, in science, math., computing, engineering, manufacturing, construction per 1000 of population aged 20-29 – Augstākās izglītības absolventi zinātnē, matemātikā, informātikā, inženierzinātnēs, ražošanā, būvniecībā uz 1000 iedzīvotājiem vecumā 20–29 gadi (Eurostat).

G5 – Dzimumu līdztiesība

G5.1 Gender pay gap in unadjusted form, % of average gross hourly earnings of men – Dzimumu atalgojuma plaša neizlīdzinātā formā, % vidējās bruto stundas algas vīriešiem (Eurostat);

G5.2 Gap in higher educational attainment level, females - males, aged 15-64, percentage points – Atšķirība augstākās izglītības līmenī, sievietes – vīrieši, vecumā 15–64 gadi, procentu punkti (Eurostat);

G5.3 Gender employment gap, males - females, aged 15-64, percentage points – Dzimumu nodarbinātības atšķirība, vīrieši – sievietes, vecumā 15–64 gadi, procentu punkti (Eurostat);

G5.4 People gap with good or very good perceived health, males - females, population aged 16 or over, percentage points – Atšķirība labas vai ļoti labas pašvērtētās veselības īpatsvarā, vīrieši – sievietes, iedzīvotāji vecumā 16 gadi un vairāk, procentu punkti (Eurostat);

G5.5 Seats held by women in national parliament (%) – Sieviešu amatu īpatsvars valsts parlamentā (%) (Eurostat);

G5.6 Percentage of women among elected local level representatives – Sieviešu īpatsvars starp ievēlētajiem vietējā līmeņa pārstāvjiem (CEMR);

G5.7 People gap /males-females/ with at least basic digital skills, 16-74 years old – Atšķirība iedzīvotāju digitālo pamatprasmju līmenī, vīrieši – sievietes, vecumā 16–74 gadi (Eurostat).

G6 – Mājsaimniecības aprīkojums un pakalpojumi

G6.1 Population having neither a bath, nor a shower in their dwelling, % of population – Iedzīvotājiem, kuriem mājoklī nav ne vanna, ne duša, % iedzīvotāju (Eurostat);

G6.2 Population not having indoor flushing toilet for the sole use, % of population – Iedzīvotājiem, kuriem nav privātas iekšējās tualetes ar skalošanu, % iedzīvotāju (Eurostat);

G6.3 Population connected to at least secondary wastewater treatment, % – Iedzīvotāji, kuri pieslēgti vismaz sekundārā notekūdeņu attīrīšanai, % (Eurostat).

G7 – Enerģija un siltums

G7.1 Share of renewable energy in heating and cooling – Atjaunojamās enerģijas īpatsvars siltumapgādē un dzesēšanā (Eurostat);

G7.2 Share of population unable to keep home adequately warm by poverty status, % – Iedzīvotāju īpatsvars, kuri nevar pienācīgi apsildīt mājokli pēc nabadzības statusa, % (Eurostat).

G8 – Nodarbinātība

G8.1 Employment rate, population from 20 to 64 years – Nodarbinātības līmenis, iedzīvotāji vecumā 20–64 gadi (Eurostat);

G8.2 Newly employed (percentage of people in current job for 12 months or less, in total employment), from 15 to 64 years – Jaunievēlētie darbinieki (personas, kuras esošajā darbā strādā 12 mēnešus vai mazāk, % no kopējās nodarbinātības), vecumā 15–64 gadi (Eurostat);

G8.3 Long-term unemployment rate, % of active population from 15 to 74 years – Ilgtermiņa bezdarba līmenis, % no aktīvās iedzīvotāju grupas vecumā 15–74 gadi (Eurostat).

G9 – Inovācijas un uzņēmējdarbība

G9.1 Employment in high- and medium-high technology manufacturing and knowledge-intensive services; % of total employment – Nodarbinātība augsto un vidēji augsto tehnoloģiju ražošanā un zināšanu intensīvās pakalpojumu nozarēs; % no kopējās nodarbinātības (Eurostat);

G9.2 Percentage of enterprises who have ERP software package to share information between different functional areas (10+ employees) – Uzņēmumu īpatsvars, kuriem ir ERP programmatūra informācijas apmaiņai starp dažādām funkcijām (10+ darbinieki) (Eurostat);

G9.3 Percentage of the gross value added by industry (B – E, NACE Rev.2) – Nozares (B–E, NACE Rev.2) radītās pievienotās vērtības īpatsvars (Eurostat);

G9.4 Percentage of enterprises (10+ employees) having a fast (> 30 Mbit/sec) fixed broadband connection – Uzņēmumu (10+ darbinieki) īpatsvars ar ātru (>30 Mbit/s) fiksēto platjoslas savienojumu (DAS);

G9.5 Percentage of enterprises that provided any type of training to develop ICT related skills of their personnel – Uzņēmumu īpatsvars, kas nodrošināja jebkādas apmācības darbinieku IT prasmju attīstībai (EIS);

G9.6 Percentage of SMEs who introduced at least one product innovation or process innovation either new to the enterprise or new to their market – MVU īpatsvars, kas ieviesa vismaz vienu produktu vai procesa inovāciju, kas jauna uzņēmumam vai tirgum (EIS);

G9.7 Percentage of SMEs who introduced at least one new organisational innovation or marketing innovation – MVU īpatsvars, kas ieviesa vismaz vienu jaunu organizatorisko vai mārketinga inovāciju (EIS);

G9.8 Percentage of SMEs with in-house innovation activities – MVU īpatsvars ar iekšējām inovāciju aktivitātēm (EIS);

G9.9 Total innovation expenditure as percentage of total turnover of enterprises, excluding intramural and extramural R&D expenditures – Kopējie izdevumi inovācijām kā % no uzņēmumu kopējā apgrozījuma, izņemot iekšējos un ārējos pētniecības un attīstības izdevumus (EIS);

G9.10 Percentage of SMEs with innovation co-operation activities – MVU īpatsvars ar sadarbības inovāciju aktivitātēm (EIS).

G11 – Mājsaimniecību dzīves apstākļi

G11.1 Population living in a dwelling with a leaking roof, damp walls, floors or foundation or rot in window frames of floor by poverty status, % of population – Iedzīvotāji, kas dzīvo mājoklī ar noplūdušu jumtu, mitriem mūriem, grīdām vai pamatiem vai sapuvušiem logu rāmjiem, sadalot pēc nabadzības statusa, % (Eurostat);

G11.2 Young people neither in employment nor in education and training, from 15 to 24 years, percentage – Jaunieši, kas nav nodarbināti un neapgūst izglītību vai apmācību, vecumā 15–24 gadi, % (Eurostat);

G11.3 Average number of rooms per person – Vidējais istabu skaits uz vienu personu (Eurostat).

G12 – Atkritumu pārstrāde

G12.1 Recycling rate of municipal waste, % of generated – Pašvaldību atkritumu pārstrādes īpatsvars, % no saražotajiem atkritumiem (Eurostat);

G12.2 Recycling rate of e-waste, % – Elektroiekārtu atkritumu pārstrādes īpatsvars, % (Eurostat).

G13 – Vide un piesārņojums

G13.1 Greenhouse gas emissions, tonnes per capita – Siltumnīcefekta gāzu emisijas, tonnas uz vienu iedzīvotāju (Eurostat);

G13.2 Pollution, grime or other environmental problems, % of households – Piesārņojums, netīrumi vai citi vides problēmas, % mājsaimniecību (Eurostat).

G15 – Meži

G15.1 Share of forest area, % of total land area – Meža zemes īpatsvars, % no kopējās zemes platības (Eurostat);

G16 – Sabiedriskās pārvaldes uztvere un drošība

G16.1 Individuals interacting online with public authorities in the last 12 months, % of total – Personas, kas pēdējo 12 mēnešu laikā sadarbojušās tiešsaistē ar valsts iestādēm, % no kopskaita (DAS);

G16.2 Perceived independence of the justice system, % of population perceived as very good or fairly good – Tiesu sistēmas uztvertā neatkarība, % iedzīvotāju, kas to vērtē kā ļoti vai diezgan labu (Eurobarometer);

G16.3 Crime, violence or vandalism in the area, % of households – Noziedzība, vardarbība vai vandālisms apkaimē, % mājsaimniecību (Eurostat).

G17 – Interneta savienojums

G17.1 Households with fast (> 30 Mbit/sec) fixed broadband connection, % of total –
Mājsaimniecības ar ātru (>30 Mbit/s) fiksēto platjoslas savienojumu, % no kopskaita (DAS).